

- 考试时间：
- **2021年6月28日13：20—15：20**
- 考试地点：**(三)211**

- 答疑时间：
- **2021年6月28日上午9：00—11：30**
- 答疑地点：**(三)101**

总复习

- 一. 凸集与凸函数
- **1.** 凸集的定义、性质

设 S_1 和 S_2 是两个凸集, β 实数, 则

- (1) $\beta S_1 = \{\beta x \mid x \in S_1\}$ 是凸集;
- (2) $S_1 + S_2 = \{x^{(1)} + x^{(2)} \mid x^{(1)} \in S_1, x^{(2)} \in S_2\}$ 是凸集;
- (3) $S_1 - S_2 = \{x^{(1)} - x^{(2)} \mid x^{(1)} \in S_1, x^{(2)} \in S_2\}$ 是凸集;
- (4) $S_1 \cap S_2$ 是凸集;

2. 极点的定义

设 S 是非空集合, $x \in S$, 若 x 不能表示成 S 中两个不同点的凸组合, 即若假设 $x = \lambda x^{(1)} + (1 - \lambda)x^{(2)}$, 必推出 $x = x^{(1)} = x^{(2)}$, 则称 x 是凸集 S 的极点。

要求: 会证明或判断一个点是否是极点.

结论： 设 $S = \{x \mid Ax = b, x \geq 0\}$ 为非空集合， d 是非零向量，则 d 是 S 的方向的充要条件是 $d \geq 0$ 且 $Ad = 0$ 。

2. 凸集分离定理

- (1) 会应用凸集分离定理
- (2) 掌握**Farkas**定理和**Gordan**定理和证明方法，会应用这两个定理证明相应的题目。

3. 凸函数(凹函数)

要求：掌握凸(凹)函数的定义、性质及判断方法，会证明或判断一个函数是否是凸(凹)函数。

凸规划

- 凸规划：求凸函数在凸集上的极小点。

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & g_i(x) \geq 0, i = 1, \dots, m \\ & h_j(x) = 0, j = 1, \dots, l \end{aligned}$$

若 $f(x)$ 是凸函数， $g_i(x)(i = 1, \dots, m)$ 是凹函数， $h_j(x)(j = 1, \dots, l)$ 是线性函数，则原问题为凸规划。

性质：凸规划的局部极小点就是整体极小点，且极小点的集合为凸集。

要求：会判断一个模型是否为凸规划

线性规划部分

LP的标准形式

- 1、极小化型
- 2、约束方程为等式
- 3、所有的决策变量为非负值
- 4、约束方程的右端项系数为非负值

$$\min \quad z = \sum_{j=1}^n c_j x_j$$

$$\begin{aligned} s.t. \quad & \sum_{j=1}^n a_{ij} x_j = b_i \quad i = 1, \dots, m \\ & x_j \geq 0 \quad j = 1, \dots, n \end{aligned}$$

$$\begin{aligned} \min \quad & z = cx \quad c_{1 \times n} \\ s.t. \quad & Ax = b \quad A_{m \times n} \quad b_{m \times 1} \geq 0 \\ & x \geq 0 \quad x_{n \times 1} \end{aligned}$$

- **1. 基本概念:**
- 可行域(线性规划的可行域是凸集).
- 解的情形:无解(无可行解)、无界解(不存在有限的最优解)、最优解(最优解与最优值的区别)、局部最优解与全局最优解.
- 可行解、基本解、基、基变量、非基变量、基本可行解、非退化(退化)的基本可行解。

- **2. 基本性质:**
- 若线性规划问题存在有限最优解，则目标函数的最优值可在某个极点达到。
- 基本可行解与可行域极点之间的关系---等价。
- 基本可行解的存在问题：有可行解，一定有基本可行解。

单纯形法

$$\begin{cases} \min & f(x) = cx \\ s.t. & Ax = b \\ & x \geq 0 \end{cases}$$

1. 存在初始基 B , 使得 $B^{-1}b \geq 0$.

如何判断该问题是否有最优解?

如何判断一个基是否为最优基?

如何判断该问题是否有无穷多最优解?

用单纯形表求解问题：

	x_B	x_N	右端
x_B	I_m	$B^{-1}N$	$B^{-1}b$
	0	$c_B B^{-1}N - c_N$	$c_B B^{-1}b$

假设 $\bar{b} = B^{-1}b \geq 0$, 有一基本可行解

$$x = \begin{pmatrix} x_B \\ x_N \end{pmatrix} = \begin{pmatrix} B^{-1}b \\ 0 \end{pmatrix}$$

(1) 若 $c_B B^{-1}N - c_N \leq 0$ (极小化问题), 则现行基本可行解为最优解。

(2) 若存在 $c_B B^{-1}P_j - c_j > 0$, 用 **主元消去法** 求改进的基本可行解

2. 寻找初始基本可行解

$$\begin{cases} \min & f(x) = cx \\ s.t. & Ax = b \\ & x \geq 0 \end{cases}$$

两阶段法

$$\begin{cases} \min & e^T x_a \\ s.t. & Ax + x_a = b \quad e = (1 \ 1 \cdots 1)^T \\ & x, x_a \geq 0 \end{cases}$$

大**M**法

$$\begin{cases} \min & cx + Me^T x_a \\ s.t. & Ax + x_a = b \quad e = (1 \ 1 \cdots 1)_{m \times 1}^T \quad M > 0 \\ & x \geq 0 \end{cases}$$

对偶原理

	min	max	
• 变量	≥ 0	\leq	约束 方程
• 量	≤ 0	\geq	
•	无限制	$=$	
•			
• 约束	\geq	≥ 0	变 量
• 束	\leq	≤ 0	
• 方	$=$	无限制	
• 程			

- 会写各种形式（对称、非对称、一般形式）的对偶问题；
- 掌握弱对偶定理和强对偶定理及其相关推论；
- 会用互补松弛定理求原问题或对偶问题的解；

小结

原问题(min)

对应关系

对偶问题(max)

有最优解




有最优解

无界解



不可行

不可行



无界解

对偶单纯形法

- 掌握对偶单纯形方法（对偶可行的基本解，如何求初始对偶可行的基本解）。
- 与原单纯形法的区别：
- 原单纯形法保持原问题的可行性，对偶单纯形法保持所有检验数 $wP_j - c_j \leq 0$ ，即保持对偶问题的可行性。
- 特点：先选择出基变量，再选择进基变量。

- **5. 灵敏度分析**
- 改变非基变量和基变量价格系数后，原问题最优解和最优值的改变，会求最优解不变时价格系数的变化范围；
- 右端向量改变对最优解及最优值的影响，会求最优基不变时，右端向量的变化范围；

最优性条件

- 无约束问题的极值条件:

定理1:(一阶必要条件)设函数 $f(x)$ 在点 \bar{x} 处可微, 若 \bar{x} 是局部极小点, 则 $\nabla f(\bar{x}) = 0$.

定理2:(二阶必要条件)设 $f(x)$ 在 \bar{x} 处二阶可微, 若 \bar{x} 是局部极小点, 则 $\nabla f(\bar{x}) = 0$, 且 $Hessian$ 矩阵 $\nabla^2 f(\bar{x})$ 是半正定的。

定理3: 设函数 $f(x)$ 在点 \bar{x} 处二次可微, 若梯度 $\nabla f(\bar{x}) = 0$, 且 $Hessian$ 矩阵 $\nabla^2 f(\bar{x})$ 正定, 则 \bar{x} 是严格局部极小点。

推论：对于正定二次函数 $f(x) = \frac{1}{2}x^T Ax + b^T x + c$
(A 对称正定)，有唯一极小点 $x^* = -A^{-1}b$.

定理4：设 $f(x)$ 是定义在 E^n 上的可微凸函数， $\bar{x} \in E^n$ ，
则 \bar{x} 为整体极小点的充要条件是 $\nabla f(\bar{x}) = 0$.

约束极值问题的最优性条件

对 $\min_{x \in E^n} f(x)$, 设 $\bar{x} \in E^n$ 是任给一点,

$d \neq 0$, 若存在 $\delta > 0$, 使得对任意的 $\lambda \in (0, \delta)$, 有 $f(\bar{x} + \lambda d) < f(\bar{x})$, 则称 d 为 $f(x)$ 在点 \bar{x} 处的下降方向 (descent direction)。

$$F_0 = \left\{ d \mid \nabla f(\bar{x})^T d < 0 \right\}$$

称为点 \bar{x} 处的下降方向集。

定义： 设集合 $S \subset E^n$, $\bar{x} \in clS$, d 为非零向量, 若存在数 $\delta > 0$, 使得对任意 $\lambda \in (0, \delta)$, 都有

$$\bar{x} + \lambda d \in S$$

则称 d 为集合 S 在 \bar{x} 的可行方向 (feasible direction)。

$$D = \left\{ d \mid d \neq 0, \bar{x} \in clS, \exists \delta > 0, \forall \lambda \in (0, \delta), \text{有 } \bar{x} + \lambda d \in S \right\}$$

\bar{x} 处的可行方向锥。

定理2(KKT必要条件) 考虑问题
$$\begin{cases} \min f(x) \\ s.t. \quad g_i(x) \geq 0, i = 1, \dots, m \\ \quad \quad h_j(x) = 0, j = 1, \dots, l \end{cases}$$

设 \bar{x} 为可行点, $I = \{i \mid g_i(\bar{x}) = 0\}$. $f, g_i (i \in I)$ 在 \bar{x} 处可微,
 $g_i (i \notin I)$ 在 \bar{x} 连续, $h_j (j = 1, \dots, l)$ 在 \bar{x} 连续可微, 向量集

$$\{\nabla g_i(\bar{x}), \nabla h_j(\bar{x}) \mid i \in I, j = 1, \dots, l\}$$

线性无关, 若 \bar{x} 是局部最优解, 则存在数 $w_i, i \in I$
 和 $v_j (j = 1, \dots, l)$, 使得

$$\nabla f(\bar{x}) - \sum_{i \in I} w_i \nabla g_i(\bar{x}) - \sum_{j=1}^l v_j \nabla h_j(\bar{x}) = 0.$$

$$w_i \geq 0 \quad (i \in I).$$

定理2'(KKT必要条件) 考虑问题
$$\begin{cases} \min f(x) \\ s.t. \quad g_i(x) \geq 0, i = 1, \dots, m \\ \quad \quad h_j(x) = 0, j = 1, \dots, l \end{cases}$$

设 \bar{x} 为可行点, $I = \{i \mid g_i(\bar{x}) = 0\}$. f, g_i 在 \bar{x} 处可微, $h_j (j = 1, \dots, l)$ 在 \bar{x} 连续可微, 向量集

$$\{\nabla g_i(\bar{x}), \nabla h_j(\bar{x}) \mid i \in I, j = 1, \dots, l\}$$

线性无关, 若 \bar{x} 是局部最优解, 则存在数 $w_i, i \in I$ 和 $v_j (j = 1, \dots, l)$, 使得

$$\nabla f(\bar{x}) - \sum_{i=1}^m w_i \nabla g_i(\bar{x}) - \sum_{j=1}^l v_j \nabla h_j(\bar{x}) = 0$$

$$w_i g_i(\bar{x}) = 0, i = 1, 2, \dots, m$$

$$w_i \geq 0 \quad i = 1, 2, \dots, m.$$

定义广义的**Lagrange**函数:

$$\begin{aligned} L(x, w, v) &= f(x) - \sum_{i=1}^m w_i g_i(x) - \sum_{j=1}^l v_j h_j(x) \\ &= f(x) - w^T g(x) - v^T h(x) \end{aligned}$$

其中 $w = (w_1, w_2, \dots, w_m)^T$

$v = (v_1, v_2, \dots, v_l)^T$

乘子向量

$g(x) = (g_1(x), \dots, g_m(x))^T$

$h(x) = (h_1(x), \dots, h_l(x))^T.$

定理2'(KKT必要条件) 考虑问题
$$\begin{cases} \min f(x) \\ s.t. \quad g_i(x) \geq 0, i = 1, \dots, m \\ \quad \quad h_j(x) = 0, j = 1, \dots, l \end{cases}$$

设 \bar{x} 为可行点, $I = \{i \mid g_i(\bar{x}) = 0\}$. f, g_i 在 \bar{x} 处可微, $h_j (j = 1, \dots, l)$ 在 \bar{x} 连续可微, 向量集

$$\{\nabla g_i(\bar{x}), \nabla h_j(\bar{x}) \mid i \in I, j = 1, \dots, l\}$$

线性无关, 若 \bar{x} 是局部最优解, 则存在乘子向量 $\bar{w} \geq 0, \bar{v}$, 使得

$$\nabla_x L(\bar{x}, \bar{w}, \bar{v}) = 0$$

定理3.(一阶充分条件)

$$\text{设问题} \begin{cases} \min f(x) \\ \text{s.t. } g_i(x) \geq 0 \quad i = 1, 2, \dots, m \\ h_j(x) = 0 \quad j = 1, 2, \dots, l \end{cases}$$

中, f 是凸函数, $g_i (i = 1, 2, \dots, m)$ 是凹函数,

$h_j (j = 1, 2, \dots, l)$ 是线性函数, S 为可行域,

$\bar{x} \in S$, $I = \{i \mid g_i(\bar{x}) = 0\}$ 。 f 和 $g_i (i \in I)$ 在点 \bar{x} 可微,

$h_j (j = 1, 2, \dots, l)$ 在点 \bar{x} 连续, $g_i (i \notin I)$ 在点 \bar{x} 连续,

且在 \bar{x} 处 KKT 条件成立, 则 \bar{x} 为整体极小点。

推论1: 设 (NP) 是凸规划, 则 $\bar{x} \in S$ 是整体最优解

$\Leftrightarrow \bar{x}$ 是 KKT 点。

定理（二阶必要条件）：设 \bar{x} 是 (NP) 的局部最优解， $f, g_i (i = 1, \dots, m)$ 和 $h_j (j = 1, \dots, l)$ 二次连续可微，且在 \bar{x} 处， $\{\nabla g_i(\bar{x}), i \in I, \nabla h_j(\bar{x}), j = 1, \dots, l\}$ 为线性无关组，则存在 \bar{w}, \bar{v} ，使 $(\bar{x}, \bar{w}, \bar{v})$ 为 (LM) 的解且矩阵 $\nabla^2 L_x(\bar{x}, \bar{w}, \bar{v})$ 在子空间 \bar{G} 上是半正定的，其中

$$\bar{G} = \left\{ d \left| \begin{array}{l} \nabla g_i(\bar{x})^T d = 0, i \in I \text{ 且 } \bar{w}_i > 0 \\ \nabla g_i(\bar{x})^T d \geq 0, i \in I \text{ 且 } \bar{w}_i = 0 \\ \nabla h_j(\bar{x})^T d = 0, j = 1, 2, \dots, l \end{array} \right. \right\}.$$

定理（二阶充分条件）：设 $f, g_i (i=1, \dots, m)$ 和 $h_j (j=1, \dots, l)$ 是二次连续可微函数， \bar{x} 为可行解，若存在 \bar{w}, \bar{v} ，使 $(\bar{x}, \bar{w}, \bar{v})$ 为 (LM) 的解且矩阵 $\nabla^2 L_x(\bar{x}, \bar{w}, \bar{v})$ 在子空间 G 上是正定的，则 \bar{x} 是严格局部极小点。

其中

$$G = \left\{ d \neq 0 \left| \begin{array}{l} \nabla g_i(\bar{x})^T d = 0, i \in I \text{ 且 } \bar{w}_i > 0 \\ \nabla g_i(\bar{x})^T d \geq 0, i \in I \text{ 且 } \bar{w}_i = 0 \\ \nabla h_j(\bar{x})^T d = 0, j = 1, 2, \dots, l \end{array} \right. \right\}.$$

算法

- 二次终止性的定义：若某个算法对于任意的正定二次函数，从任意的初始点出发，都能经有限步迭代达到其极小点，则称该算法具有二次终止性。

一维搜索

- 一维搜索的定义
- 一维搜索的性质:

设目标函数 $f(x)$ 具有一阶偏导数, $x^{(k+1)}$ 由下列规则产生:

$$\begin{cases} f(x^{(k)} + \lambda_k d^k) = \min_{\lambda} f(x^{(k)} + \lambda d^k) \\ x^{(k+1)} = x^{(k)} + \lambda_k d^k \end{cases}$$

则有 $\nabla f(x^{(k+1)})^T d^k = 0$ 。

使用导数的最优化方法

- 最速下降方向的定义:

$$d^{(k)} = -\nabla f(x^{(k)})$$

- 牛顿方向:

$$d^{(k)} = -\nabla^2 f(x^{(k)})^{-1} \nabla f(x^{(k)})$$

共轭方向法

共轭方向

定义： 设 A 是 $n \times n$ 对称正定矩阵，若 E^n 中的两个方向 $d^{(1)}$ 和 $d^{(2)}$ 满足

$$(d^{(1)})^T A d^{(2)} = 0$$

则称这两个方向关于 A 共轭，或称它们关于 A 正交。

性质

设 A 是 n 阶对称正定矩阵， $d^{(1)}, d^{(2)}, \dots, d^{(k)}$ 是 k 个 A 共轭的非零向量，则这 k 个向量线性无关。

定理（扩张子空间定理,expanding subspace theorem）

设有函数
$$f(x) = \frac{1}{2} x^T A x + b^T x + c$$

其中 A 为 n 阶对称正定矩阵, $d^{(1)}, d^{(2)}, \dots, d^{(k)}$ 是 A 共轭的非零向量。以任意的 $x^{(1)} \in E^n$ 为初始点, 依次沿 $d^{(1)}, d^{(2)}, \dots, d^{(k)}$ 进行一维搜索, 得到点 $x^{(2)}, x^{(3)}, \dots, x^{(k+1)}$, 则 $x^{(k+1)}$ 是 $f(x)$ 在线性流形

$$\begin{aligned} M_k \left(x^{(1)}; \{d^{(1)}, d^{(2)}, \dots, d^{(k)}\} \right) &= \left\{ x \left| x = x^{(1)} + \sum_{i=1}^k \mu_i d^{(i)}, \mu_i \in R \right. \right\} \\ &= x^{(1)} + B_k \end{aligned}$$

上的唯一极小点。特别的, 当 $k = n$ 时, $x^{(n+1)}$ 是 $f(x)$ 在 E^n 上的唯一极小点。

可行方向法:

$$\begin{cases} \min f(x) \\ s.t. \quad Ax \geq b \\ \quad \quad Ex = e \end{cases} \quad (1)$$

定理: 设 \bar{x} 是问题(1)的可行解,在 \bar{x} 点处,有

$$A_1 \bar{x} = b_1, A_2 \bar{x} > b_2$$

其中 $A = \begin{bmatrix} A_1 \\ A_2 \end{bmatrix}$, $b = \begin{bmatrix} b_1 \\ b_2 \end{bmatrix}$, 则非零向量 d 是 \bar{x} 处的可行方向

的充要条件是 $A_1 d \geq 0, Ed = 0$.

$$(2) \quad \begin{cases} \min \nabla f(x)^T d \\ s.t. \quad A_1 d \geq 0 \\ \quad \quad Ed = 0 \\ \quad \quad |d_j| \leq 1, j = 1, 2, \dots, n \end{cases}$$

在问题(1)中，设 x 是可行解，在点 x 处有

$A_1 x = b_1, A_2 x > b_2$ ，其中

$$A = \begin{bmatrix} A_1 \\ A_2 \end{bmatrix}, \quad b = \begin{bmatrix} b_1 \\ b_2 \end{bmatrix},$$

则 x 是 KKT 点的充要条件是问题(2)的目标函数最优值 $= 0$ 。

推论1: 若 Q 是正交投影矩阵, 则 $Q^T = Q$, $QQ = Q$.

推论2: 若 Q 是正交投影矩阵, 则 Q 是半正定的.

定理: 设 x 是问题(1)的可行解, 在点 x 处, 有 $A_1x = b_1$,
 $A_2x > b_2$, 其中

$$A = \begin{bmatrix} A_1 \\ A_2 \end{bmatrix} \quad b = \begin{bmatrix} b_1 \\ b_2 \end{bmatrix}$$

又设 $M = \begin{bmatrix} A_1 \\ E \end{bmatrix}$ 为满秩矩阵, 令

$$P = I - M^T (MM^T)^{-1} M$$

若 $P\nabla f(x) \neq 0$, 令 $d = -P\nabla f(x)$, 则 d 为下降可行方向。

定理2: 设 x 是问题(1)的可行解, 在点 x 处, 有 $A_1x = b_1$,
 $A_2x > b_2$, 其中

$$A = \begin{bmatrix} A_1 \\ A_2 \end{bmatrix} \quad b = \begin{bmatrix} b_1 \\ b_2 \end{bmatrix}$$

又设 $M = \begin{bmatrix} A_1 \\ E \end{bmatrix}$ 为满秩矩阵, 令

$$P = I - M^T (MM^T)^{-1} M$$

$$W = (MM^T)^{-1} M \nabla f(x) = \begin{bmatrix} u \\ v \end{bmatrix}$$

其中 u 和 v 分别对应于 A_1 和 E 。设 $P \nabla f(x) = 0$, 则

1. 若 $u \geq 0$, 则 x 为 KKT 点;

2. 如果 u 中含有负分量, 不妨设 $u_j < 0$, 这时从 A_1 中去掉 u_j 对应的行, 得到 \hat{A}_1 。令

$$\hat{M} = \begin{bmatrix} \hat{A}_1 \\ E \end{bmatrix} \quad \hat{P} = I - \hat{M}^T (\hat{M} \hat{M}^T)^{-1} \hat{M}$$

$$d = -\hat{P} \nabla f(x)$$

则 d 为 x 处的下降可行方向。

$$W = (MM^T)^{-1} M \nabla f(x) = \begin{bmatrix} u \\ v \end{bmatrix}$$

Wolfe既约梯度法

$$\min f(x)$$

$$s.t. \quad Ax = b, \quad x \geq 0$$

$A_{m \times n}$, $r(A) = m$, $b_{m \times 1}$, f 是 E^n 上的连续可微函数

$$A = (B, N), \quad x = \begin{pmatrix} x_B \\ x_N \end{pmatrix}$$

$$\min f(x_B, x_N)$$

$$s.t. \quad Bx_B + Nx_N = b$$

$$x_B, x_N \geq 0$$



$$\min F(x_N)$$

$$s.t. \quad x_B, x_N \geq 0$$

$$x_B = B^{-1}b - B^{-1}Nx_N$$

$$\Rightarrow F(x_N) = f(x_B(x_N), x_N)$$

$f(x)$ 的既约梯度为

$$r(x_N) = \nabla F(x_N)$$

$$= \nabla_{x_N} f(x) - (B^{-1}N)^T \nabla_{x_B} f(x)$$

定理 设 x 是可行解, $A = (B, N)$ 是 $m \times n$ 矩阵, B 为 m 阶可逆矩阵, $x = (x_B^T, x_N^T)^T$, $x_B > 0$, 函数 f 在点 x 处可微, 又设

$$d = \begin{pmatrix} -B^{-1}Nd_N \\ d_N \end{pmatrix},$$

其中
$$d_{N_j} = \begin{cases} -x_{N_j} r_j(x_N) & r_j(x_N) > 0 \\ -r_j(x_N) & r_j(x_N) \leq 0 \end{cases}$$

如果 $d \neq 0$, 则 d 是下降可行方向, 而且 $d = 0$ 的充要条件是 x 为 KKT 点。